


Base de Datos Vectoriales

SEMANA 10

Heider Sanchez
hsanchez@utec.edu.pe

Tratamiento de Datos No Estructurados



En las aplicaciones modernas, resulta fundamental el procesamiento eficiente de datos no estructurados para permitir consultas **basadas en su contenido**. Esto requiere la integración de técnicas avanzadas de indexación, que **optimicen la velocidad y precisión de las búsquedas**.

```
-- Buscar artículos que contengan la frase "big data y análisis de  
datos" en su contenido
```

```
SELECT id, titulo, contenido
```

```
FROM articulos
```

```
WHERE MATCH(contenido_vector, "big data y análisis de datos");
```

```
-- Buscar rostros similares a una foto de un empleado
```


```
SELECT id, nombre, fecha_registro, rostro_path
```

```
FROM fotos_empleados
```

```
WHERE MATCH(rostro_vector, ExtractVector('/path/to/any_photo.jpg'));
```

Base de Datos Vectoriales: Áreas de Aplicación

Content based Image Retrieval



https://www.youtube.com/watch?v=M_Gziz-S4A0

Music Retrieval Demo

The aim of this demo is to automatically find audio clips that sound "similar," in some sense, to an example clip. Here's a brief [explanation](#) of how the demo works. Even if you think [Gregorian chant sounds nothing like Nat King Cole](#), do listen with an open ear: the similarities are often surprising.

Some things to search for:

[Piano music](#) · [Grunge rock](#) · [Acoustic guitar](#) · [Reggae](#) · [Jazz](#) · [Medieval plainsong](#)




1.000 AmericanMusicClub+IfIHadAHammer
0.785 SoftSounds+BrazillianSuiteNo2
0.714 SoftSounds+BeijaEu
0.711 Guru+Loungin
0.708 LizPhair+XRayMan
0.700 SoftSounds+CalypsoGetaway
0.689 EricClapton+LayDownSally
0.688 HappyMondays+LooseFit
0.679 AmericanMusicClub+Hollywood4-5-92
0.674 JeffersonAirplane+GoodShepherd
0.630 BoneyJames+JustBetweenUs
0.622 LizPhair+SupportSystem
0.618 Coolio+MamamlnLoveWitAGangsta
0.614 JeffersonAirplane+EskimoBlueDay
0.611 EricClapton+WonderfulTonight

[Search for similar files](#) [Play selected file](#) [Reset](#)

<http://www.rotorbrain.com/foote/musicr/>

Base de Datos Vectoriales: Áreas de Aplicación

- Digital Libraries
- News-on-Demand
- Video-on-Demand
- Music database
- Telemedicine
- Biometry
- Manufacturing Industries
- ChatGPT
- Google Búsqueda



1.



Modelos de Recuperación Multimedia

Introducción

¿Qué es una Base de Datos Multimedia (MMDB)?

- Es una colección de datos multimedia relacionados.
- Los datos multimedia incluyen uno o más tipos de datos de medios como texto, imágenes, objetos gráficos (incluidos dibujos, bocetos e ilustraciones) secuencia de animación, audio y video.



¿Y un Sistema de Gestión de Base de Datos Multimedia?

- Sería entonces un software que gestione diferentes tipos de datos potencialmente representados en una amplia variedad de formatos y en una amplia gama de fuentes de medios.
- Proporciona soporte para tipos de datos multimedia y facilita la creación, almacenamiento, acceso, consulta y control de una base de datos multimedia.

¿Cuáles son los problemas y desafíos?

- Los datos multimedia consisten en una variedad de formatos o representaciones de archivos que incluyen TIFF, BMP, PPT, IVUE, FPX, JPEG, MPEG, AVI, MID, WAV, DOC, GIF, EPS, PNG, etc. Debido a las restricciones en la conversión de un formato a otro, el uso de los datos en un formato específico también ha sido limitado. Por lo general, el tamaño de los datos multimedia es grande (como el video); por lo tanto, los datos multimedia a menudo requieren un gran almacenamiento.


¿Cuáles son los problemas y desafíos?

- La base de datos multimedia consume mucho tiempo de procesamiento, así como ancho de banda.
- Algunos tipos de datos multimedia, como las secuencias de video, audio y animación, tienen requisitos temporales lo cual tienen implicaciones en su almacenamiento, manipulación y presentación.
- Los datos de imágenes, video y gráficos tienen también limitaciones espaciales en términos de su contenido.

Arquitectura de Base de Datos Multimedia

Basado en el principio de autonomía:

- Cada tipo de medio está organizado de una manera específica y adecuada para ese tipo de medio.
- Necesidad de computar uniones a través de diferentes estructuras de datos.
- El procesamiento de consultas es relativamente rápido debido al uso de estructuras especializadas.




Arquitectura de Base de Datos Multimedia

Basado en el principio de uniformidad:

- Una única estructura abstracta para indexar todos los tipos de medios.
- Resume la parte común de los diferentes tipos de medios (**¡difícil!**) - metadatos.
- Una estructura - fácil implementación.

Gran desafío



Recuperación Basado en Contenido [imagenes]

- "Basado en el contenido" significa que la búsqueda analiza el contenido de la imagen en lugar de los metadatos, como palabras claves, etiquetas o descripciones asociadas con la imagen.
- El término "contenido" en este contexto puede referirse a colores, formas, texturas o cualquier otra información que se pueda derivar de la propia imagen.

Vector de Características

- Un sistema de recuperación basado en contenido procesa la información contenida en los datos del objeto y crea **una abstracción de su contenido** en términos de atributos característicos.
- Cualquier operación de **consulta trata únicamente con esta abstracción** en lugar de con el objeto en sí.
- Por lo tanto, cada objeto insertado en la base de datos se analiza, y una representación compacta de su contenido se almacena en un **vector de características o signature**.

Embedding

- Representación vectorial denso que captura la semántica de datos (texto, imágenes, audio) en un espacio matemático de alta dimensión donde la similitud geométrica refleja similitud semántica.
- Es una representación aprendida automáticamente por modelos de machine learning o Deep learning
- Captura relaciones semánticas y contextuales

Vectores Característicos vs Embeddings

Representaciones numéricas de objetos multimedia o entidades

VECTORES CARACTERÍSTICOS

Representación basada en características diseñadas manualmente.

Objetos / Entidades	Extracción de características (manual / específica del dominio)	Vector característico (típicamente alta dimensionalidad y disperso)
 Imagen	Color, bordes, texturas, formas, histograma, ...	[0, 0, 3, 0, 12, 0, ..., 0]
 Audio	MFCC, tono, energía, ritmo, espectro, ...	[0, 1.2, 0, 0, 0, 5.1, ...]
 Video	Fotogramas clave, movimiento, color, histogramas, ...	[2, 0, 0, 1, 0, 0, ..., 7]
 Texto	Frecuencia de palabras (BoW), TF-IDF, n-gramas, ...	[0, 4, 0, 0, 13, 0, ..., 0]
 Persona	Edad, género, altura, color de cabello, ...	[0, 0, 5, 0, 0, 0, ..., 1]
 Lugar	Coordenadas, clima, población, tipo de zona, ...	[0, 1, 0, 0, 0, 3, ..., 0]
		⋮


VS

EMBEDDINGS

Representación aprendida automáticamente por modelos a partir de datos.

Objetos / Entidades (mismos ejemplos)	Modelo de aprendizaje (Autoaprendizaje)	Embedding (baja dimensionalidad y denso)
 Imagen	 Aprende patrones y relaciones semánticas directamente de los datos	[0.21, -0.37, 0.82, ..., 0.15]
 Audio		[-0.41, 0.11, -0.26, ..., 0.67]
 Video		[0.53, -0.22, 0.31, ..., -0.12]
 Texto		[0.12, 0.73, -0.35, ..., 0.09]
 Persona		[-0.28, 0.44, 0.11, ..., -0.31]
 Lugar		[0.07, -0.19, 0.62, ..., 0.23]
		⋮

Espacio semántico (2D)



- Baja dimensionalidad (decenas a cientos)
- Densos (pocos o ningún cero)
- Aprendidos automáticamente
- Capturan significado y contexto
- Generalizan mejor a nuevos datos y dominios



- Alta dimensionalidad (miles a millones)
- Muy dispersos (muchos ceros)
- Dependen de conocimiento experto
- Capturan información superficial
- Generalizan mal a nuevos datos o dominios


2.



Modelos de Recuperación Multimedia


Búsqueda por Similitud

Esquema general




Esquema general


Indexing



Querying




Búsqueda por Similitud



Imágenes similares *entre* si, deben mapearse a puntos cercanos en el espacio.



Búsqueda por Similitud



Búsqueda por Similitud

- **Modelo de búsqueda**

- Extracción de características
 - Descriptor (vector)
 - Estructura del descriptor está oculta al usuario
- Función de similitud
 - Permite comparar descriptores
 - Debe “imitar” la similitud semántica de los objetos
 - Similitud: parte concordante entre objetos



$$fs(P1, P3) > fs(P1, P2)$$

Medidas de Distancia

- Modelos para definir objetivamente “similitud”

- *Similitud basada en distancias:*


- Una función de distancia mide la **disimilitud** entre objetos

- A mayor distancia, más disímiles los objetos
 - Un objeto P tiene (por lo general) distancia 0 a sí mismo

- Se puede formalizar matemáticamente en

- **Espacios vectoriales**

- **Espacios métricos**



Medidas de Distancia

Manhattan (p=1):

$$d(x, y) = \sum_{i=1}^D |x_i - y_i|$$

Euclidiana (p=2):

$$d(x, y) = \sqrt{\sum_{i=1}^D |x_i - y_i|^2}$$

Máximo (p=infinito):


$$d(x, y) = \max_{1 \leq i \leq D} |x_i - y_i|$$

Similitud Coseno
(Angular)


$$\cos(\theta) = \frac{a \cdot b}{\|a\| \times \|b\|}$$

Producto Punto
(Dot Product)

$$\text{dot}(a, b) = \sum (a_i * b_i)$$



Medidas de Distancia



Euclidean Distance

QUÉ CONSIDERA



Magnitud, escala y diferencias absolutas.

USO TÍPICO



KNN




Clustering



Coordenadas físicas



Datos métricos



Cosine Similarity

QUÉ CONSIDERA



Dirección o patrón, no la magnitud.

USO TÍPICO



Embeddings



NLP / Texto



Imágenes



Audio

Medidas de Distancia

- Transformación entre similitud (s) - disimilitud (d) o viceversa

i. $d = 1 - s$

ii. $s = \frac{1}{d+1}, s = 1 - \frac{d - \min_d}{\max_d - \min_d}$

iii. $s = e^{-d}$

- En general, cualquier función monótona decreciente sirve

Medidas de Distancia

- Propiedades de funciones de disimilitud:

No-negatividad: $d(x, y) \geq 0$

Reflexividad: $d(x, y) = 0 \Leftrightarrow x = y$

Simetría: $d(x, y) = d(y, x)$

Desigualdad triangular: $d(x, z) \leq d(x, y) + d(y, z)$

- Una función que cumpla con estas cuatro propiedades se denomina *métrica*

Medidas de Distancia

- Formas cuadráticas

$$d(x, y) = \sqrt{(x - y)' A (x - y)}$$

- A : matriz de similitud

- Ejemplos

- Euclidiana (A =matriz identidad)
 - Mahalanobis (A =inversa de matriz de covarianza)
 - Signature Quadratic Form Distance (SQFD)
 - Permite medir distancia entre vectores de distinta dimensión

Complejidad de las distancias

- Minkowski: $O(D)$
- Forma cuadrática: $O(D^2)$

Espacios Métricos

- Objetos se pueden representar como:
 - Vectores multidimensionales: $x \in \mathcal{R}^D$
 - D : dimensión del espacio
 - Histogramas
 - Normalizados
 - Se manejan igual que los vectores
 - Signatures
 - Conjuntos de vectores con un peso asociado

Espacios Métricos

- Objetos de X son directamente comparados utilizando δ .
- δ indica el grado de disimilitud entre dos objetos.
- Ejemplo: *strings* + distancia de edición
 - *Distancia de edición*: mínimo # de inserciones, borrados o substituciones para transformar un string en otro.

Espacios Vectoriales


- Espacio vectorial: caso particular de espacio métrico.
- $\mathbb{R}^d$: d -tuplas de números reales (*vectores*)

$$x \in \mathbb{R}^d \Rightarrow x = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_d \end{bmatrix}, \quad x_i \in \mathbb{R}$$

Búsqueda por Similitud

Las dos técnicas de búsqueda mas comunes son:

- Búsqueda por rango
- Búsqueda de los K vecinos más cercanos.



- KNN retorna k elementos.
- Búsqueda por rango retorna entre 0 y toda la colección.

Búsqueda por Similitud

- Sea $\mathbb{U}$ el conjunto de datos multimedia (BD)
- **Consulta por rango**

Objeto de consulta: $q \in \mathbb{X}$


Radio de tolerancia: $r \in \mathbb{R}^+$

$$(q, r) = \{u \in \mathbb{U}, \delta(u, q) \leq r\}$$

- **Bola de consulta:** subespacio definido por q y r

Búsqueda por Similitud


- Ejemplo de consulta por rango en $(\mathbb{R}^2, L_2)$




$$(q, r) = \{u_2, u_4, u_6, u_7\}$$

Búsqueda por Similitud

- Problema de la consulta por rango: ¿Qué valor debe tener el radio de tolerancia?



Muy pequeño: no retorna nada



Muy grande: retorna demasiado

Búsqueda por Similitud

- **Consulta por vecinos más cercanos (k -NN)**

Objeto de consulta: $q \in \mathbb{X}$


Número de vecinos: $k \in \mathbb{N}$

Retorna conjunto $\mathbb{C}$, $|\mathbb{C}| = k$ tal que

$$\forall x \in \mathbb{C}, y \in \mathbb{U} - \mathbb{C}, \delta(x, q) \leq \delta(y, q)$$

Búsqueda por Similitud

- Ejemplo de consulta por 3-NN en $(\mathbb{R}^2, L_2)$



$$3 - NN(q) = \{u_2, u_6, u_7\}$$

Búsqueda por Similitud


- **Consulta por ranking incremental:**

- A menudo uno no conoce ni un radio de tolerancia adecuado ni un valor de k razonable
 - Ejemplo: búsqueda en Internet
- Se desea un resultado ordenado por distancias al objeto de consulta: **ranking**.
- También conocida como consulta ***give-me-more***


Búsqueda por Similitud

- Consulta por ranking incremental:

- Dado un objeto de consulta q , se repite el llamado de la función ***getnext(ki)*** para retorna los siguientes ***ki*** objetos relevantes, hasta que se alcance la cantidad deseada de objetos.



6x *getnext*(1) para q'



6x *getnext*(1) para q''

Búsqueda por Similitud: eficiencia

- **¿Cómo se mide la eficiencia?**

- Se relaciona con el costo de búsqueda
- Se mide el tiempo de CPU y tiempo de E/S (acceso a memoria secundaria)
- Estructuras de datos para agilizar búsquedas.
 - Índices multidimensionales (*spatial access methods*) [BBK01]
 - Índices métricos (*metric access methods*) [CNB01]

Búsqueda por Similitud: efectividad


- **¿Cómo se mide la efectividad?**

- Efectividad: calidad de la respuesta retornada por el motor de búsqueda.
 - Ejemplo en espacios vectoriales: función de transformación efectiva mapea dos objetos similares en puntos cercanos.
- Descriptores finos se obtienen con resoluciones altas
 - Pero no necesariamente implican mejor efectividad
- Evaluación de la efectividad:
 - Medir su habilidad de recuperar objetos relevantes de la BD y de evitar los objetos no relevantes.

Búsqueda por Similitud: efectividad

¿Qué tan bueno son los objetos recuperados?

- Por lo general, no todo el conjunto de objetos recuperados son relevantes para la consulta.



DB

	Relevant Objects	No-Relevant Objects
Retrieval Objects	True Positive (TP)	False Positive (FP)
No-Retrieval Objects	False Negative (FN)	True Negative (TN)

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Son usados para evaluar el resultado obtenido

Búsqueda por Similitud: efectividad

¿Qué tan bueno son los objetos recuperados?

- Cuantificación de la similitud entre objetos recuperados y objetos relevantes.

Precision: ¿Cuántos de los objetos recuperados son relevantes?


Recall: ¿Cuántos de los objetos relevantes fueron encontrados?

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Búsqueda por Similitud: efectividad

- Relación empírica entre Precision y Recall



Búsqueda por Similitud: colecciones de referencia

- Es una colección de documentos usados para probar modelos de RI y algoritmos [BR99].
- Usualmente incluye:
 - Conjunto de objetos
 - Conjunto de consultas
 - Conjunto de objetos relevantes a cada consulta
- Son difíciles de construir

Búsqueda por Similitud: colecciones de referencia

- **TREC collection**

- Text REtrieval Conference, empezó en 1992.
- Colección de documentos de TREC
- Varios gigabytes de datos
- Documentos provienen de fuentes diversas

- URL: <https://trec.nist.gov/>

Búsqueda por Similitud: colecciones de referencia

- **MIR Flickr**

- Se inició con 25.000 imágenes de alta calidad con anotaciones
- En 2010 fue extendida a 1 millón de imágenes más descriptores para las imágenes (+100 Gb de información)

- URL: <http://press.liacs.nl/mirflickr/>

Búsqueda por Similitud: colecciones de referencia

- **CoPhIR (Content-based Photo Image Retrieval)**

- Una de las mayores colecciones de imágenes disponibles para investigación (106 millones)
- Se compone de:
 - Imágenes
 - Thumbnails
 - XML con metadatos (uno por imagen)
 - Descriptores para imágenes (MPEG-7)

- **URL:** <http://cophir.isti.cnr.it/>

Referencias

- [BBK01] C. Böhm, S. Berchtold, and D. Keim. Searching in high-dimensional spaces: Index structures for improving the performance of multimedia databases. *ACM Computing Surveys*, 33(3):322—373, 2001.
- [BR99] R. Baeza-Yates, B. Ribeiro-Neto. *Modern Information Retrieval*. Addison-Wesley, 1999.
- [CNB01] E. Chávez, G. Navarro, J. Marroquín, and R. Baeza-Yates. Searching in metric spaces. *ACM Computing Surveys*, 33(3):273—321, 2001

Laboratorio 10



3.



Modelos de Recuperación Multimedia

Búsqueda de Imágenes

Búsqueda de imágenes

- Búsqueda por contenido de la imagen misma
 - Contenido derivado de la representación interna de la imagen (píxeles)
 - Evita los problemas de las anotaciones manuales
 - Características a considerar
 - Colores
 - Histogramas de colores
 - Correlograma de colores
 - Descriptores de imágenes
 - Gradientes en puntos clave de imagen
 - Cuantización para "palabras visuales"
 - Texturas: estructuras de segmentos de imágenes (madera, piedra, etc.)
 - Formas (contornos): modelo de similitud morfológico.


Búsqueda de imágenes: basado en el color

- Histograma de colores

- Distribución de colores de píxel en la imagen.
- No se guarda información espacial
- Similitud basado en la distancia entre histogramas.

- Correlograma de colores

- Histograma de color en función de la distancia entre píxeles.
- Distribución del color del píxel más información espacial.
- Similitud basada en la diferencia de correlogramas.




Búsqueda de imágenes: basado en el color


- Comparación de métodos
 - Histograma de colores
 - Correlograma de colores
- Los correlogramas son mejores para la recuperación de imágenes.



Imágenes con diferentes histogramas de color pero de correlogramas similares.



Imágenes con histogramas de color idénticos pero con diferentes correlogramas.



Búsqueda de imágenes: basado en el color

- De todas formas es un problema difícil...



Búsqueda de imágenes: basado en descriptores


- SIFT Features
 - Scale Invariant Feature Transform (2004: David Lowe, UBC)
- Seleccionar regiones keypoint en la imagen desde los extremos en el espacio escalado
 - Diferentes imágenes tienen diferentes números de keypoint.
- Calcular los vectores característicos X para cada región keypoint
 - Ejemplo: basado en Edge Histogram genera vectores de tamaño 128.
- La imagen es representada por N SIFT features
 - Features son los vectores $X_1, \dots, X_N$
 - N varía según la imagen.



Búsqueda de imágenes: distancia

- **Distancia Euclidiana:**

- Sean H^P y H^Q los histogramas de colores de las imágenes P y Q .



$$\delta(P, Q) = \sqrt{(H^P - H^Q) \cdot (H^P - H^Q)^T}$$

$$\delta(RED, PINK) = \sqrt{2}, \quad \delta(RED, BLUE) = \sqrt{2}, \quad \delta(PINK, BLUE) = \sqrt{2}$$

Búsqueda de imágenes: distancia

- Problemas de la distancia euclidiana:
 - En el ejemplo anterior, todos los pares de imágenes tienen distancia $\sqrt{2}$.
 - No se tiene en cuenta el hecho que el rojo se parece más al rosado que al azul.
 - **No se consideran las interrelaciones entre dimensiones (semántica del contexto).**

Búsqueda de imágenes: distancia

- **Forma Cuadrática:**

- Definición: sea A una matriz de similitud. Se cumple que:

$$\delta(P, Q) = \sqrt{(H^P - H^Q) \cdot A \cdot (H^P - H^Q)^T} = \sqrt{\sum_i \sum_j a_{ij} (H_i^P - H_i^Q) \cdot (H_j^P - H_j^Q)}$$

- Los valor $a_{i,j}$ de la matriz A describen la similitud entre las dimensiones i y j de los vectores (bins i y j del histograma).
- Para el ejemplo, dada la matriz se

obtienen las distancias:

$$A = \begin{bmatrix} 1 & 0,9 & 0 \\ 0,9 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\delta_A(RED, PINK) = \sqrt{0,2}, \quad \delta_A(RED, BLUE) = \sqrt{2}, \quad \delta_A(PINK, BLUE) = \sqrt{2}$$

Búsqueda de imágenes: distancia

- **Forma Cuadrática:**

- Ejemplos de matrices de similitud:

$$a_{ij} = \left(1 - \frac{d_{ij}}{d_{\text{máx}}}\right)$$

$$a_{ij} = e^{-\sigma \cdot \left(\frac{d_{ij}}{d_{\text{máx}}}\right)^2}, \quad \sigma \text{ constante}$$

- $d_{i,j}$ es la distancia entre colores i y j .

Búsqueda de imágenes: distancia

- **Forma Cuadrática:**

- Adaptabilidad para el Usuario
 - Similitud es inherentemente subjetiva
 - Es posible que un usuario no esté satisfecho con la matriz de similitud A utilizada
 - Construir de nuevo un índice al cambiar A puede ser muy costoso
 - Se desearía tener una técnica más flexible, que permitiera modificar A al momento de realizar una consulta

Búsqueda de imágenes: reconocimiento de rostros

- **Reconocimiento de rostros**

- Detectar rostros en imágenes.
- Búsqueda por similitud de rostros para reconocer los rostros detectados.
- Ej: Búsqueda avanzada de Google para imágenes con rostros.

- **Librerías:**

- Javascript: [face-api.js](https://face-api.js.com/)
- Python: [face-recognition](https://face-recognition.readthedocs.io/en/latest/)



Face Recognition

Photo Collection




Detect Faces in Photo Collection



Búsqueda de imágenes: reconocimiento de rostros

FACE RECOGNITION PIPELINE

1. Input & Landmark Detection



2. Geometric Alignment




Normalized, Frontal Face

2. Geometric Alignment



3. Global Descriptor Extraction
(Face Embedding)

CNN (Deep Neural
Network Network)
Feature Extractor



FACE EMBEDDING
(GLOBAL DESCRIPTOR - 128D Vector)
Unique "Digital Fingerprint"

Trained with
Triplet Loss

4. Comparison & Recognition

100	0.00				FD
300	0.00	100	0	0	0
1000	0.00	0.00	100	0	0

> Threshold

Distance Metric
(e.g. Euclidean)

100	0.00	100	0	0	0
300	0.00	100	0	0	0
1000	0.00	0.00	100	0	0

Database Face B


✓ MATCH / NO-MATCH

100	0.00	100	0	0	0
300	0.00	100	0	0	0
1000	0.00	0.00	100	0	0

Segmentación Automática de Videos Grabados

- Play video and view slides
 - Skip to next slide
 - **Skip to next relevant slide**

StainedGlass Photo Collages 02-22-06 4:11 PM



Wed, 22 Feb 2006 16:12:07

StainedGlass
Photo Collage Web Application

- Creates stained-glass like photo collage automatically
 - Allows summarizing an event with one photo collage
 - Collage can be rearranged and adjusted by the user
 - Collages can be emailed and showcase on the StainedGlass or personal Web server
- Enhances online photo sharing experience
- Integrates easily with any existing Online Print Services
- Interfaces to Flickr

16:15 16:20

Slides marked by
black lines

**Relevant Slides marked
by red squares**

Segmentación Automática de Videos Grabados

Contexto:


Colección de videos de conferencias (por ejemplo, material para una clase). El objetivo es encontrar únicamente la parte específica de una conferencia que se desea visualizar.

Método de indexación:

- Captura del audio y video de la conferencia.
- Captura del material de presentación (diapositivas).
- Extracción del texto contenido en las diapositivas.
- Segmentación del video basada en los cambios de diapositiva.
- Creación de un índice textual con palabras clave asociadas a cada segmento del video según la diapositiva correspondiente.
- Construcción de un índice espacio-temporal que relacione los segmentos de video y audio con su posición en el tiempo.

Método de búsqueda:

- Búsqueda por palabras claves.
- Reproducción del video a partir del segmento relevante identificado.
- Búsqueda mediante otro segmento de video (por similitud de contenido o contexto).





Búsqueda de audio musical

● Proceso:

- Calcular vectores de características espectrales, como los coeficientes cepstrales en las frecuencias de Mel (MFCC).
- Cuantizar estas características para construir un histograma de audio.
- El histograma resultante representa la distribución general de los sonidos en una pista.
- **Nota:** Este enfoque no conserva el orden temporal de los sonidos, lo que puede limitar la precisión en ciertas aplicaciones.

● Ejemplo


- <http://www.rotorbrain.com/foote/musicr/>




[Evaluation of MFCC estimation techniques for music similarity | IEEE Conference Publication | IEEE Xplore](#)

Búsqueda Multimedia: Representación Temporal

- Los datos de video, pueden pensarse mejor como series de tiempo ...



Gun-Draw



[Towards Parameter-Free Data Mining](#)